

PROPUESTA DE INVESTIGACIÓN FORMAL

Construcción de software para la transformación del territorio.

Camilo Alberto Palacios Turriago

Institución Universitaria Digital de Antioquia
Facultad de Ingeniería
Semillero de desarrollo de software

Docente: Boris Alberto Salleg Royero

Bogotá D.C.
11 de junio de 2026

Introducción

Bogotá se ha ganado un lugar importante en Latinoamérica por el uso de la bici y su red de ciclorrutas, pero la verdad es que el aumento de los robos está poniendo todo ese avance en riesgo. El problema es que la seguridad se ha venido manejando con herramientas estadísticas un poco "estáticas", como el Kernel (KDE), que básicamente te muestran qué pasó en el pasado pero no entienden variables que cambian todo el tiempo ni logran predecir dinámicas de delincuencia más complejas.

Para este 2026, la propuesta es ir más allá y usar analítica moderna con algoritmos de Machine Learning, específicamente *XGBoost*. Pero no se trata de meter datos por meterlos; si solo usamos las denuncias históricas, corremos el riesgo ético de crear sesgos que terminen estigmatizando o sobre-vigilando solo las zonas periféricas. Para evitar esto, en esta investigación vamos a integrar el enfoque CPTED (Prevención del Delito Mediante el Diseño Ambiental). O sea, no solo vemos el crimen, sino también qué tan buena es la iluminación y cómo influyen el entorno y hasta el clima.

El proyecto se va a centrar en Usme y Rafael Uribe Uribe, que son dos localidades con una situación geoespacial bien complicada: tienen muchas laderas, zonas donde la visibilidad es mala y un flujo enorme de ciclistas que salen a trabajar muy temprano o vuelven tarde en la noche.

Para que esto funcione, vamos a montar un *pipeline* de datos abiertos (un proceso ETL) para unificar la información de entidades como SIEDCO, UAESP e IDIGER. Lo bueno es que el modelo no será una "caja negra"; vamos a usar valores *SHAP* para que los resultados sean explicables y transparentes.

Al final, este software encaja perfectamente con lo que buscamos en el semillero "Construcción de software para la transformación del territorio". La meta no es solo mejorar métricas técnicas como el PAI o el $\$PEI^*\$$, sino entregar una herramienta real y ética que ayude a cuidar la vida y el bolsillo de los que nos movemos en bici por la ciudad.

2. FORMULACIÓN DE OBJETIVOS

Objetivo general

Mi proyecto consiste en diseñar un modelo de Machine Learning para predecir el riesgo en la red de ciclorrutas de Usme y Rafael Uribe Uribe. Voy a usar el algoritmo XGBoost y a cruzarlo con variables de diseño urbano (CPTED). El objetivo final es hacer un análisis espacio-temporal; es decir, ver en qué puntos y a qué horas es más peligroso andar en bici por esas localidades.

Objetivos específicos

La idea es armar un pipeline de integración de datos (ETL) que nos permita cruzar la información histórica de hurtos de bicicletas del SIEDCO con otras variables clave. Vamos a integrar datos georreferenciados de iluminación pública de la UAESP y registros de lluvias del IDIGER, enfocándonos específicamente en lo que pasa en Usme y Rafael Uribe Uribe.

Para la parte del modelo, voy a entrenar un XGBoost. El reto aquí es que, como trabajamos con datos geográficos, hay mucha autocorrelación, así que para evitar el sobreajuste voy a usar una validación cruzada por bloques espaciales (*Spatial Block K-Fold*). De esta forma, los resultados en ambas localidades serán mucho más fiables.

Finalmente, no quiero que el modelo se quede como una "caja negra". Voy a implementar un módulo de explicabilidad usando valores SHAP. Con esto, puedo documentar científicamente qué tanto influyen las deficiencias del entorno físico (basándome en los principios CPTED) en el riesgo de robo para los tramos viales que estamos analizando.

3. JUSTIFICACIÓN METODOLÓGICA DE LA DELIMITACIÓN TERRITORIAL

- Elegimos trabajar con Usme y Rafael Uribe Uribe principalmente porque estas dos localidades son el ejemplo claro de lo que pasa con la segregación urbana y los problemas de infraestructura en las zonas periféricas de la ciudad.
- Por un lado, está el tema del diseño y la seguridad. El terreno en estas zonas es bien complicado, con muchas laderas y vías que no siguen un orden fijo. Esto hace que sea muy difícil que el alumbrado público funcione de manera uniforme, creando puntos ciegos y zonas oscuras. Para nosotros, esto es el escenario ideal para poner a prueba las teorías de diseño ambiental (como lo del CPTED), porque se nota mucho cómo el entorno físico afecta directamente la visibilidad.
- Otro punto clave es la rutina de la gente que vive allá. Hay muchísimos biciusuarios que se mueven por necesidad laboral; salen de madrugada, tipo 4 o 6 de la mañana, para cruzar la ciudad hacia el norte o el centro, y vuelven ya de noche. Lo que pasa es que en esos horarios la afluencia de personas baja un montón y, sumado al clima de la zona, se crean momentos donde el riesgo de inseguridad se dispara. Básicamente, la falta de gente en la calle y las condiciones del entorno terminan facilitando que se cometan delitos.

4. ESTADO DEL ARTE Y MARCO TEÓRICO DE VANGUARDIA (EJE A)

- Para entender cómo se distribuye el riesgo de delitos en las rutas para peatones o ciclistas, lo primero es apoyarse en teorías clásicas como la de la Actividad Rutinaria y la de los Patrones del Delito. Básicamente, estas nos dicen que el crimen no ocurre al azar, sino que se concentra de forma predecible en ciertos puntos y caminos que la gente usa a diario.
-
- Por mucho tiempo, las estrategias de vigilancia se basaron en herramientas como el KDE (Estimación de Densidad de Kernel), que servía para marcar "puntos calientes" en el mapa. El problema es que estos métodos eran muy estáticos; se quedaban solo con lo que ya había pasado y no permitían cruzar datos en tiempo real, como el clima o el estado de la infraestructura. Por eso, para este 2026, lo que se está haciendo es usar modelos más avanzados como *XGBoost*. Este tipo de algoritmos son geniales porque pueden procesar un montón de datos heterogéneos y detectar patrones que antes se nos escapaban.
- Sin embargo, no todo es tecnología pura. Instituciones como Fair Trials (2024) han advertido sobre un problema ético grave: el sesgo de los datos. Si alimentamos a una inteligencia artificial solo con registros de capturas o denuncias viejas, lo que hacemos es "automatizar" los prejuicios, provocando que la policía siempre termine vigilando de más a los barrios periféricos y vulnerables.
- Para que esto no pase en zonas como Usme o Rafael Uribe Uribe, la literatura académica propone un enfoque más integral. La idea es no mirar solo el historial de delitos, sino también variables físicas basadas en el diseño ambiental (lo que llamamos CPTED). O sea, tener en cuenta si hay buena iluminación o si hay instituciones cerca que sirvan como "guardianes". Además, para que todo sea transparente, se están usando herramientas de explicabilidad como *SHAP*, que permiten entender exactamente por qué el modelo está arrojando ciertos resultados y asegurar que no estemos castigando a un barrio solo por ser pobre.

5. PLAN DE DATOS ABIERTOS LOCALIZADO (EJE B)

Para armar este análisis, saqué toda la información de las plataformas oficiales del Distrito, trabajando siempre con el sistema de referencia MAGNA-SIRGAS que es el que maneja IDECA.

Primero, me bajé los datos de SIEDCO (de la Secretaría de Seguridad) sobre el hurto de bicicletas. Lo que hice fue filtrar los registros para quedarme solo con lo que pasa en Usme y Rafael Uribe Uribe. En la metodología, me pareció clave separar los casos: una cosa es el hurto simple, que es más por un descuido o factor de oportunidad, y otra muy distinta es el hurto calificado, donde ya hay violencia o armas de por medio.

También metí el inventario de la UAESP sobre el alumbrado público. Me enfoqué en mapear los postes de luz que están cerca de las ciclorrutas en estas dos localidades. La idea es ver cómo ha sido el cambio de las luces de sodio a las LED y fijarme en la potencia de los vatios para estructurar un índice que nos diga qué tan segura es la zona de noche.

Por último, usé los datos del IDIGER para el tema del clima. Revisé los históricos y las lecturas de las estaciones de lluvia del sistema de alerta de Bogotá que están por ahí cerca. El punto aquí es ver si cuando hay picos de lluvia, baja la "vigilancia natural" en la vía y si eso tiene algo que ver con la seguridad en esos momentos.

6. PIPELINE DE VALIDACIÓN Y MÉTRICAS CIENTÍFICAS (EJE D)

Ajuste de clasificación en ciencia de datos

- Lo más importante aquí es la seguridad de la persona que va en la bici. Si el sistema ignora un tramo peligroso (lo que sería un falso negativo), el ciclista terminaría metiéndose en una zona de riesgo, y eso es justo lo que queremos evitar. Por eso, decidimos ajustar el umbral del software para priorizar el **recall** o sensibilidad, fijando una meta de más del 85%. Básicamente, el objetivo es que no se nos escape ningún punto crítico que pueda poner en peligro a alguien.
- $$\text{Recall} = \frac{\text{Verdaderos Positivos (VP)}}{\text{Verdaderos Positivos (VP)} + \text{Falsos Negativos (FN)}}$$

Métricas de eficiencia criminológica (National Institute of Justice - NIJ)

A ver, si queremos saber si de verdad los patrullajes preventivos en el distrito están sirviendo de algo o si nada más estamos dando vueltas, hay que auditar la operación con un par de métricas que son fundamentales.

- La primera es el **PAI (Índice de Precisión Predictiva)**. En español simple, lo que hace es medir si los delitos realmente se están concentrando en esas zonas que nosotros marcamos como de alto riesgo, comparándolas con el tamaño total del área. Básicamente es nuestra forma de validar si le estamos atinando al blanco o si de plano estamos poniendo el ojo donde no pasa nada.
- $$PAI(H) = \frac{\left(\frac{n(H)}{N(S)}\right)}{\left(\frac{|H|}{|S|}\right)}$$
- Luego tenemos el **PEI (Índice de Eficiencia Predictiva Modificado)**, que ya se va más por el lado de la eficiencia pura. Lo que hace es comparar qué tan bien se porta nuestro algoritmo frente al límite máximo teórico de delitos que se podrían detectar en esa misma superficie. O sea, nos sirve un montón para darnos cuenta de qué tan cerca estamos de ese "escenario ideal" de captura de delitos.
- $$PEI^*(H) = \frac{PAI(H)}{PAI_{\max}(H)} = \frac{n(H)}{n^*(H)}$$

Estrategia contra el sobreajuste espacial

- La verdad es que no nos servía usar el K-Fold aleatorio de toda la vida. Como los datos de zonas como Usme y Rafael Uribe Uribe suelen estar muy correlacionados con lo que tienen al lado, aplicar el método tradicional nos iba a meter un sesgo importante. Por eso, decidimos cambiar el enfoque y usar una Validación Cruzada por Bloques Espaciales (*Spatial Block K-Fold*). Básicamente, lo que hicimos fue separar los conjuntos de entrenamiento y validación de forma más estricta, usando las UPZ y los hexágonos como divisiones independientes. Así nos aseguramos de que la cercanía geográfica no nos "contamine" los resultados y que el modelo realmente aprenda a generalizar.

Conclusiones

- Aquí tienes una versión reescrita con un tono más natural, como si lo estuvieras explicando en una entrega de proyecto o una exposición de semillero:

¿Por qué elegir estas zonas?

- Elegimos trabajar con Usme y Rafael Uribe Uribe porque funcionan como el laboratorio perfecto para este proyecto. Son zonas que representan muy bien los desafíos reales de la ciudad: tienen una geografía de laderas complicada y la iluminación falla en muchos puntos. Además, los flujos de personas que entran y salen en las madrugadas y noches las hacen muy vulnerables. Esto nos permite poner a prueba las teorías de Patrones del Delito y CPTED en un entorno real y exigente, no solo en el papel.

Evitando los sesgos de siempre.

- Algo clave en este trabajo es que no queríamos que el algoritmo se limitara a repetir los prejuicios de las denuncias históricas del SIEDCO, porque eso suele llevar a una sobrevigilancia injusta en los barrios periféricos. Para evitarlo, cruzamos la información con datos de infraestructura de la UAESP (qué tan potentes son las luces) y factores del IDIGER (como la lluvia). Así, el modelo se vuelve más ético y objetivo, entendiendo que el riesgo no es solo "culpa" de la zona, sino también de qué tan descuidado esté el entorno físico.

La tecnología detrás del modelo

- En la parte técnica, decidimos usar *XGBoost* junto con valores *SHAP*. Elegimos esto porque los métodos tradicionales de "mapas de calor" (como el KDE) se quedan cortos y son muy estáticos. Lo que logramos aquí es crear una arquitectura de "caja blanca"; es decir, no es un proceso misterioso, sino que podemos explicar con claridad por qué el modelo marca un tramo de la ciclorruta como peligroso. Es una forma científica de procesar los datos abiertos de Bogotá sin perder la transparencia.

Lo que queremos lograr en el territorio

- Al final, todo esto se alinea con la meta del semillero de crear software que transforme el territorio. No nos conformamos con la teoría: estamos optimizando el sistema para que tenga un *Recall* superior al 85% y evaluando todo con índices criminológicos serios (como el PAI y el PEI*). Queremos que esto sea una herramienta real y auditable que sirva para tomar decisiones que, literalmente, protejan la vida y la seguridad de quienes nos movemos en bici por la ciudad.

Referencias

Gorr, W., & Olligschlaeger, A. (2020). Rotational grid, PAI-maximizing crime forecasts. Office of Justice Programs (OJP). <https://www.ojp.gov/pdffiles1/nij/grants/251203.pdf>

Kounadi, O., Ristea, A., Araujo, A., & Leitner, M. (2020). A systematic review on spatial crime forecasting. National Institutes of Health (PMC). <https://pmc.ncbi.nlm.nih.gov/articles/PMC7319308/>

Ruan, Y., & Zhang, H. (2025). Evaluation of a Hyperparameter Tuned Random Forest Algorithm Based on Artificial Bee Colony for Improving Accuracy and Precision of Crime Prediction Model. American Journal of BioScience. <https://sciencepublishinggroup.com/article/10.11648/j.ajbes.20251103.16>

Yuan, J., & Wang, L. (2026). Optimal prediction threshold and spatial characteristics of burglary crime across cities. Taylor & Francis / Journal of Spatial Science. <https://www.tandfonline.com/doi/full/10.1080/24754269.2026.2665854>

Fair Trials. (2024). Inteligencia artificial en la seguridad pública y en el sistema penal en América Latina. Fair Trials Report. <https://www.fairtrials.org/app/uploads/2024/08/Inteligencia-artificial-en-la-seguridad-publica-y-en-el-sistema-penal-en-America-Latina.pdf>

Raleigh City Planning. (2022). New Bern Corridor Study: Crime Prevention Through Environmental Design (CPTED). City of Raleigh. <https://cityofraleigh0drupal.blob.core.usgovcloudapi.net/drupal-prod/COR28/NBCSCPTED.pdf>

Sáenz, M. A. (2023). La criminología predictiva: ¿un futuro próximo o una ficción en la distancia? Novum Jus, 17(1). <https://novumjus.ucatolica.edu.co/article/view/5982/6031>

Shepley, M., & Sachs, N. (2025). Community-engaged crime prevention through environmental design and reductions in violent and firearm crime. National Institutes of Health (PMC). <https://pmc.ncbi.nlm.nih.gov/articles/PMC12404146/>

Infraestructura de Datos Espaciales para Bogotá (IDECA). (2019). Índice de condiciones de seguridad nocturna por localidad. Bogotá D.C. Alcaldía Mayor de Bogotá. <https://www.ideca.gov.co/recursos/mapas/indice-de-condiciones-de-seguridad-nocturna-por-localidad-bogota-dc-ano-2019>

Secretaría Distrital de Seguridad, Convivencia y Justicia. (2025). Anexo 1: Diagnóstico detallado del plan de seguridad ciudadana. Alcaldía Mayor de Bogotá. https://scj.gov.co/sites/default/files/2025-08/Anexo%201%20-%20-%20-%20Diagn%C3%B3stico%20detallado_0.pdf

Secretaría Distrital de Seguridad, Convivencia y Justicia. (2026). Metadata del Sistema de Información Estadístico, Delincuencial, Contravencional y Operativo (SIEDCO). Dirección de Análisis de Información. https://oaiee.scj.gov.co/Documentos/Metadata_Siedco.pdf

Torres, J. E., & Martínez, A. (2021). Pronóstico del Hurto de Bicicletas en Bogotá durante la Ciclovía. Academia y Ciencia, Fundación Universitaria Los Libertadores.
<https://revistas.libertadores.edu.co/index.php/ACI/article/download/1298/1215/3467>