

Análisis de Viabilidad Técnica y Estado del Arte: Modelo Predictivo de Riesgos de Seguridad en las Ciclorrutas de Bogotá

Antecedentes y Estado del Arte de la Criminología Predictiva (Eje A)

El análisis del riesgo de seguridad en redes de transporte no motorizado se fundamenta en un sólido cuerpo de teorías criminológicas de corte ambiental y espacial. La distribución espacial del delito no ocurre de manera fortuita, sino que se alinea con patrones específicos determinados por la geografía urbana y la interacción social¹. La Teoría de la Actividad Rutinaria postula que el delito requiere de la convergencia espacio-temporal de un infractor motivado, un objetivo apropiado (el ciclista) y la ausencia de guardianes capaces¹. Esta teoría se complementa con la Teoría de los Patrones del Delito, la cual sostiene que la criminalidad se agrupa en torno a nodos cotidianos de actividad y corredores de tránsito habituales, denominados generadores o atractores de delitos². Asimismo, la Teoría de las Ventanas Rotas y la metodología de Prevención del Delito Mediante el Diseño Ambiental (CPTED) afirman que las condiciones físicas y el mantenimiento de la infraestructura —tales como el nivel de iluminación, la visibilidad natural, el control de acceso y el reforzamiento territorial— influyen directamente en la probabilidad de ocurrencia delictiva y en la percepción de seguridad de los ciudadanos¹.

A nivel global, la aplicación de la inteligencia artificial y la ciencia de datos para mitigar la inseguridad en ciclorrutas ha transitado desde análisis meramente descriptivos hacia modelos predictivos dinámicos y sistemas de vigilancia automatizados. Diversas investigaciones en entornos académicos han implementado metodologías cuantitativas avanzadas para modelar el hurto de bicicletas. Por ejemplo, estudios realizados en campus universitarios y áreas metropolitanas mediante análisis de "repetición cercana" (near-repeat analysis) han demostrado que los delitos contra la propiedad tienden a concentrarse de forma predecible en el espacio y el tiempo, especialmente en áreas de residencia estudiantil y zonas de transferencia de transporte². En Milán (Italia), se ha utilizado exitosamente el análisis aorístico para estimar ventanas de probabilidad delictiva temporal controlando la variación estacional, identificando que el setenta y seis por ciento de los robos de bicicletas ocurren en días y horas específicas⁷. Por otra parte, proyectos más recientes del año 2026, como el sistema "Ride Shield", han integrado bases de datos no relacionales como MongoDB, backends en FastAPI y visualizaciones en tiempo real para caracterizar hotspots en horas pico de la tarde (18:00 a 22:00 horas) y durante los fines de semana, permitiendo una asignación optimizada de patrullajes preventivos⁸. Asimismo, el despliegue de sistemas de videovigilancia inteligente

mediante algoritmos de detección de objetos como YOLOv5s acoplados con seguimiento multi-objeto mediante DeepSORT ha demostrado una reducción significativa del delito en estacionamientos públicos de bicicletas gracias a la generación de alertas tempranas automáticas enviadas a los operadores de seguridad en cuestión de segundos⁹.

En el contexto nacional colombiano, la aplicación de modelos predictivos y de aprendizaje automático ha ganado relevancia en los últimos años para la prevención del delito en grandes centros urbanos¹⁰. No obstante, el modelamiento enfocado específicamente en ciclistas muestra aún importantes desafíos metodológicos. Un estudio representativo en Bogotá abordó el pronóstico del hurto de bicicletas durante la jornada dominical de la Ciclovía recreativa —recolectando denuncias mensuales entre los años 2012 y 2021— mediante un modelo paramétrico de series de tiempo SARIMA¹¹. A pesar de la rigurosidad estadística en la modelación estacional, el estudio reportó un nivel de error medio (MAPE) del cincuenta y tres por ciento, lo cual evidencia las severas limitaciones de las técnicas estadísticas lineales para capturar dinámicas delictivas altamente heterogéneas y adaptativas¹¹. Para superar estas barreras, investigaciones en otras capitales intermedias del país como Bucaramanga han implementado Redes Neuronales Recurrentes (RNN) y arquitecturas de Memoria a Corto y Largo Plazo (LSTM), demostrando una precisión superior al capturar las no linealidades de los datos históricos y factores de estacionalidad horaria y climática¹². Por otra parte, enfoques prácticos se han orientado a la construcción de aplicativos móviles basados en geolocalización activa mediante localizadores GPS Tracker TK102 y plataformas Android para posibilitar la recuperación física de los vehículos hurtados¹³.

Los principales vacíos identificados en la literatura científica global y nacional radican en la falta de integración de variables dinámicas ambientales (iluminación, microclima instantáneo) con la infraestructura topológica de la vía, limitando la mayoría de los análisis a datos puramente históricos y autorregresivos⁴. Adicionalmente, el desarrollo de la policía predictiva mediante inteligencia artificial enfrenta serios cuestionamientos éticos y metodológicos en América Latina. Informes globales de derechos humanos y seguridad pública, como los publicados por Fair Trials en 2024, advierten que el uso de algoritmos basados exclusivamente en datos de denuncias policiales históricas tiende a perpetuar y profundizar sesgos sistemáticos contra poblaciones vulnerables y áreas periféricas específicas de la ciudad (reificación de sesgos), promoviendo la sobre-vigilancia y vulnerando el debido proceso¹⁵. Por ende, resulta imperativo diseñar modelos que no solo garanticen precisión matemática, sino que incorporen explicabilidad y balanceen el análisis con variables físicas de la infraestructura de transporte sostenible¹⁶.

Fuentes de Información y Referencias Académicas de la Sección

El marco conceptual e histórico analizado se sustenta en investigaciones clave del ámbito criminológico y de la ciencia de datos aplicada. Entre las fuentes primarias destaca la Universidad de Milán y el trabajo sobre análisis aorístico de Giacomo Salvaneli⁷. En el plano nacional colombiano, el estudio predictivo mediante modelos SARIMA fue liderado por E. Díaz-Pulido de la Universidad de los Libertadores¹¹, mientras que el análisis de redes neuronales recurrentes para la delincuencia fue desarrollado en la Universidad Autónoma de

Bucaramanga y la Universidad del Valle¹². Los aportes teóricos sobre CPTED y su aplicación en ciclorrutas provienen de investigaciones de la Universidad de Michigan y la Universidad Estatal de Arizona lideradas por Laney A. Rupp¹⁹. Las evaluaciones críticas sobre sesgo y derechos humanos en la seguridad pública provienen de la organización internacional Fair Trials¹⁶, y el análisis sistemático de modelos de aprendizaje automático y videovigilancia fue publicado por Hernán Yonathan Barragán-Huamán en la Revista Criminalidad de la Policía Nacional de Colombia²⁰.

Mapeo y Disponibilidad de Datos Abiertos en el Contexto de Bogotá (Eje B)

La viabilidad técnica de un modelo predictivo para la evaluación de riesgos en las ciclorrutas de Bogotá en el año 2026 está plenamente respaldada por la existencia y apertura de conjuntos de datos geográficos, administrativos y climáticos provistos por entidades del Distrito Capital. A través de la Infraestructura de Datos Espaciales para el Distrito Capital (IDECA) y el portal oficial de Datos Abiertos de Bogotá, se dispone de capas geográficas estandarizadas en formatos vectoriales interoperables como GeoPackage (GPKG), GeoJSON, Shapefiles (SHP) y servicios web del Open Geospatial Consortium (OGC) bajo el sistema de referencia MAGNA-SIRGAS (EPSG: 4686)²¹.

Para la estructuración del repositorio de datos del modelo predictivo, se han consolidado y verificado los siguientes conjuntos de datos oficiales:

Tipo de Variable	Conjunto de Datos / Dataset	Entidad Responsable	Formatos de Acceso	Atributos Críticos y Campos Clave
Historial Delictivo	Registros de Delitos y Hurto de Bicicletas (SIEDCO) ²⁴	Secretaría Distrital de Seguridad, Convivencia y Justicia (SDSCJ) ²⁴	CSV, XLSX, Servicio de mapas REST (ArcGIS Server) ²⁴	Coordenadas geométricas X-Y, fecha del hecho, hora exacta, día de la semana, código de localidad, Unidad de Planeamiento Zonal (UPZ), sexo y edad de la víctima, modalidad de hurto (atraco,

				oportunidad, cosquilleo), tipo de arma utilizada ²⁴ .
Infraestructura Vial	Red de Cicloinfraestructura - POT Bogotá D.C. ²⁸	Secretaría Distrital de Planeación (SDP) ²⁸	GPKG, GeoJSON, SHP, KMZ, DXF ²⁸	Trazado lineal de carriles exclusivos para bicicletas, cicloalamedas, estado de la vía (existente, proyectada, en formulación), tipología física del carril y longitud del tramo en metros ²⁸ .
Luminosidad Pública	Inventario de Alumbrado Público por Localidad ³⁰	Unidad Administrativa Especial de Servicios Públicos (UAESP) ³⁰	CSV, XLSX, GeoJSON, Shapefile, ESRI REST ³⁰	Geolocalización del poste, tipo de tecnología (LED, Sodio, halogenuros), potencia lumínica en vatios (W), fecha de modernización, estado de operación y red eléctrica asociada ³⁰ .
Monitoreo Climático	Estaciones de Precipitación y Temperatura ³⁴	Instituto Distrital de Gestión de Riesgos y Cambio Climático	CSV, Servicios web geográficos (Sistema de Alerta de Bogotá) ³⁵	Lectura en tiempo real e históricos de lluvias acumuladas (pluviómetros),

		(IDIGER) ³⁵		temperatura ambiente en grados Celsius, humedad relativa y velocidad del viento de 62 estaciones activas ³⁴ .
--	--	------------------------	--	--

La base de datos de criminalidad del SIEDCO constituye el núcleo analítico para modelar el comportamiento del delito. De acuerdo con el diccionario de datos de la SDSCJ, la variable "hurto de bicicletas" se deriva de un filtro estructurado aplicado sobre las denuncias generales de hurto a personas, establecimientos comerciales y residencias donde se registra formalmente un vehículo no motorizado como el bien sustraído²⁴. Esta base de datos permite clasificar los delitos bajo el Código Penal Colombiano, discriminando entre hurto simple (factor de oportunidad, que representa históricamente más del cincuenta por ciento de los casos debido a bicicletas mal parqueadas o amarradas) y hurto calificado (atraco violento, donde el victimario utiliza violencia física, armas blancas o de fuego colocando a la víctima en indefensión)²⁷. Las coordenadas espaciales exactas permiten la intersección de estos puntos con los incidentes reportados a la línea de emergencias 123 (tipificados con el código 905 para atracos en proceso)³⁸.

La disponibilidad temporal de estos datos delictivos es altamente dinámica. Al corte de los años 2024, 2025 y 2026, la implementación del plan de seguridad "Bogotá Camina Segura" y la posterior firma del "Pacto de Corresponsabilidad con Ciclistas" (diciembre de 2025) han articulado herramientas preventivas críticas como el "Registro Bici Bogotá"—la principal base de datos de control de propiedad que facilita la recuperación de vehículos y la identificación de propietarios—³⁹. El pacto ha consolidado también la creación de corredores de transporte bajo la estrategia "Rutas Seguras", facilitando un flujo constante de datos espaciales sobre acompañamientos policiales en horas y zonas críticas de la ciudad⁴⁰.

La integración de las variables ambientales y físicas en el modelo predictivo se apoya en los conjuntos de datos del IDIGER y la UAESP³⁰. El clima de Bogotá presenta comportamientos microclimáticos complejos marcados por la influencia de los Cerros Orientales, registrando picos históricos de lluvia severa durante las tardes (entre el mediodía y las 16:00 horas), lo cual desestimula el volumen de flujo peatonal y reduce los niveles de vigilancia natural en los tramos de ciclorrutas⁴². Además, la UAESP reporta el inventario de luminarias georreferenciadas actualizadas de forma anual, lo que permite calcular la densidad de luminarias LED de alta visibilidad en contraposición a las tecnologías obsoletas de sodio a nivel de manzana y Unidad de Planeamiento Zonal, conformando una variable física de primer orden para medir el "Índice de Condiciones de Seguridad Nocturna" de la cicloinfraestructura²¹.

Portales Institucionales y Recursos de Datos de la Sección

La viabilidad de los datos se fundamenta en plataformas distritales oficiales y repositorios de información pública de Bogotá. Los datos sobre el histórico de hurtos provienen del Sistema Estadístico, Delincuencial, Contravencional y Operativo (SIEDCO) de la Policía Nacional de Colombia, administrado localmente por la Secretaría Distrital de Seguridad, Convivencia y Justicia (SDSCJ)²⁴. La información espacial de la cicloinfraestructura y el ordenamiento territorial se encuentra dispuesta en el portal de Datos Abiertos de Bogotá y el portal de mapas de la Unidad Administrativa Especial de Catastro Distrital (IDECA) bajo la tutela de la Secretaría Distrital de Planeación (SDP)²¹. Por su parte, el inventario georreferenciado de luminarias públicas es gestionado y actualizado anualmente por la Unidad Administrativa Especial de Servicios Públicos (UAESP)³⁰. Las variables hidroclimatológicas provienen de la red de monitoreo del Instituto Distrital de Gestión de Riesgos y Cambio Climático (IDIGER), accesible mediante el Sistema de Alerta de Bogotá (SAB)³⁴.

Algoritmos y Técnicas de Inteligencia Artificial para el Procesamiento Espacio-Temporal (Eje C)

Para procesar de manera conjunta las variables heterogéneas espaciales (topología de la red vial, ubicación de luminarias, equipamientos policiales) y temporales (hora, día de la semana, precipitación meteorológica) y generar un índice de riesgo predictivo en tiempo real para las ciclorrutas de Bogotá, se evalúan tres enfoques algorítmicos diferenciados bajo criterios de precisión, costo computacional e interpretabilidad técnica¹⁷.

Estimación de Densidad de Kernel (KDE - Kernel Density Estimation)

La Estimación de Densidad de Kernel es un método geoestadístico no paramétrico de interpolación espacial utilizado tradicionalmente para la identificación visual de "puntos calientes" o hotspots de criminalidad en la cartografía urbana³. KDE funciona mediante la superposición de una función matemática de densidad (comúnmente Gaussiana o Cuártica) sobre cada punto geométrico de delito registrado en el historial, acumulando los valores de densidad en una superficie continua con base en un radio de búsqueda denominado ancho de banda (bandwidth)⁴⁴.

- **Ventajas:** Es una técnica computacionalmente ágil, requiere pocos recursos de infraestructura y es sumamente fácil de interpretar y visualizar en entornos de información geográfica (GIS) tradicionales mediante mapas de calor directos³.
- **Desventajas:** Se limita a un análisis puramente espacial y descriptivo basado en la densidad de eventos históricos anteriores. No posee la capacidad de asimilar variables ambientales dinámicas concurrentes (como el volumen de lluvia del IDIGER en tiempo real o el estado operativo del alumbrado de la UAESP), y es altamente sensible a la discretización del ancho de banda, lo que puede inducir a la distorsión del área real de riesgo urbano¹⁷.

Modelos de Aprendizaje de Conjunto (Random Forest, Gradient

Boosting, XGBoost)

Estos algoritmos se basan en el principio de aprendizaje supervisado mediante ensambles de árboles de decisión estructurados de forma paralela (Bagging) o secuencial para la reducción óptima del residuo del gradiente (Boosting)⁴⁵. Para modelar el riesgo delictivo, el espacio urbano se discretiza mediante una grilla de celdas cuadradas o mediante la partición por tramos físicos de ciclorrutas, donde cada unidad geométrica se asocia con un vector de variables tabulares temporales y espaciales que incluyen la hora del día, el estado del clima, el tipo de luminaria circundante y la distancia al nodo de transporte público más cercano¹⁷.

El algoritmo XGBoost (Extreme Gradient Boosting) resulta óptimo en este escenario por su velocidad de procesamiento de datos tabulares a gran escala y su resistencia al sobreajuste mediante la regularización L1 y L2 incorporada¹⁷. Para solucionar la opacidad del modelo de caja negra, se integra la metodología de explicabilidad post-hoc SHAP (Shapley Additive exPlanations) basada en teoría de juegos cooperativos¹⁷. SHAP calcula el aporte de importancia marginal de cada variable para una predicción específica, determinando de forma cuantitativa cómo influye, por ejemplo, una luminaria defectuosa combinada con una precipitación fuerte en la estimación de riesgo de un tramo de ciclorruta a las 19:00 horas¹⁷. Adicionalmente, variantes como el clasificador RF-ABC (Random Forest optimizado mediante la Colonia de Abejas Artificiales) demuestran que el ajuste heurístico de hiperparámetros mejora significativamente la robustez del ensamble frente a datos con alta correlación de ruido⁴⁶.

- **Ventajas:** Alta capacidad para procesar relaciones complejas no lineales entre variables tabulares altamente heterogéneas, excelente precisión predictiva, métricas de interpretabilidad robustas locales y globales mediante valores SHAP y bajo costo de cómputo en la fase de inferencia¹⁷.
- **Desventajas:** Requiere una fase exhaustiva y manual de ingeniería de características para proyectar la dimensión puramente geográfica (coordenadas continuas) y temporal a atributos tabulares planos, lo que puede inducir a una pérdida de la continuidad espacial de la red de transporte¹⁴.

Redes Neuronales Espacio-Temporales y Aprendizaje Profundo (LSTM-GNN, HSTT)

Los desarrollos de vanguardia en la predicción delictiva urbana han evolucionado hacia arquitecturas neuronales híbridas capaces de asimilar la estructura topológica de la ciudad de forma nativa⁴. Las Redes Neuronales de Grafos (GNN) representan la red física de ciclorrutas de Bogotá como un grafo abstracto, donde los segmentos de la vía corresponden a los nodos y las conexiones viales corresponden a las aristas, lo que permite capturar de forma orgánica la vecindad espacial de la delincuencia y el flujo de los ciclistas⁴.

Estas GNN se acoplan secuencialmente con capas de memoria recurrente (como LSTM o GRU) o mecanismos de auto-atención escasa multicabezal (Multi-head Sparse Self-attention), dando lugar a modelos híbridos como "LGSTime" o "HSTT" (Hierarchical Spatiotemporal Transformer)¹⁷. El modelo LGSTime utiliza redes LSTM y GRU para procesar series de tiempo

y capturar la estacionalidad temporal compleja de largo plazo y el comportamiento cíclico delictivo, al tiempo que introduce mecanismos de atención para ponderar dinámicamente las variables más relevantes en el espacio geográfico⁴⁷.

- **Ventajas:** Precisión predictiva superior al asimilar relaciones no lineales de alta dimensionalidad sobre la topología vial continua, eliminando la necesidad de discretización por cuadrículas arbitrarias y modelando la propagación del delito en grafos dinámicos⁴.
- **Desventajas:** Requiere grandes volúmenes de datos históricos para lograr la convergencia del modelo, presenta un costo de cómputo excesivamente elevado para el entrenamiento y mantenimiento continuo, y posee un nivel de interpretabilidad sumamente limitado, funcionando como un modelo de caja negra difícil de auditar por las autoridades locales¹⁴.

La viabilidad comparativa de estos enfoques algoritmos aplicados al contexto de la seguridad vial se estructura de la siguiente manera:

Algoritmo	Capacidad Espacial	Capacidad Temporal	Tolerancia a Ruido	Explicabilidad	Costo Computacional	Recomendación Técnica
KDE (Kernel)	Media (Suavizado estático) ⁴	Baja (No nativa) ³	Baja (Sensible a valores atípicos)	Alta (Sencillo de interpretar visualmente)	Muy Bajo ⁸	Descartado para tiempo real ; útil solo para visualización básica de líneas base ³ .
Ensembles (XGBoost / Random Forest)	Alta (Discretización por celdas/tramos) ¹⁷	Alta (Variables lag temporal) ⁴⁵	Alta (Excelente con regularización) ¹⁷	Muy Alta (Mediante modelamiento con valores SHAP) ¹⁷	Moderado (Idóneo para despliegue ligero) ¹⁷	Altamente Recomendado por su balance óptimo entre alta precisión, costo y auditoría

						algorítmica ¹⁷ .
Deep ST-Learning (GNN + LSTM / HSTT)	Excelente (Topología vial basada en grafos) ⁴	Excelente (Nativa mediante capas de memoria) ⁴⁷	Media (Propenso al sobreajuste si faltan datos) ¹⁴	Muy Baja (Arquitecturas complejas multicapa) ⁴⁶	Muy Alto (Requiere procesamiento GPU intensivo) ¹⁷	Recomendado para fases de investigación avanzada o modelación a escala macroestratégica distrital⁴.

Referencias Académicas y Tecnológicas de la Sección

El análisis comparativo de las técnicas de inteligencia artificial se alimenta de desarrollos teóricos publicados en la literatura científica de vanguardia. La evaluación sistemática de modelos de ensamble de árboles en criminología espacial está fundamentada en el estudio de optimización híbrida RF-ABC publicado en el American Journal of BioScience⁴⁶ y la revisión de algoritmos recopilada en la revista Computers, Materials & Continua⁴⁶. El desarrollo de redes neuronales espacio-temporales avanzadas se sustenta en el modelo LGSTime (LSTM-GRU-MHSA) publicado en repositorios de arXiv⁴⁷, y la arquitectura de Transformadores Espacio-Temporales Jerárquicos (HSTT) junto con la explicabilidad SHAP para la predicción delictiva detallada por investigadores en Spatiotemporal Crime Prediction¹⁷. Adicionalmente, los modelos de densidad kernel y procesos de puntos espaciotemporales se discuten ampliamente en las revisiones sistemáticas de predicción espacial de la literatura científica internacional³.

Métricas de Evaluación, Validación Científica y Mitigación de Sesgos (Eje D)

La validación científica de un modelo enfocado en la predicción del riesgo delictivo urbano requiere el despliegue de esquemas de partición y métricas que evalúen de manera rigurosa tanto el rendimiento algorítmico tradicional de la ciencia de datos como la eficiencia del modelo bajo restricciones operativas reales⁴⁴.

Métricas de Clasificación de la Ciencia de Datos

En un enfoque de clasificación binaria (donde el objetivo es predecir si un tramo específico de ciclorruta es catalogado como de "Alto Riesgo" o "Bajo Riesgo" en un intervalo horario

determinado), el modelo se evalúa a partir de la matriz de confusión:

$$\text{Precision} = \frac{\text{Verdaderos Positivos (VP)}}{\text{Verdaderos Positivos (VP)} + \text{Falsos Positivos (FP)}}$$

$$\text{Recall (Sensibilidad)} = \frac{\text{Verdaderos Positivos (VP)}}{\text{Verdaderos Positivos (VP)} + \text{Falsos Negativos (FN)}}$$

$$F_1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Para la preservación de la seguridad de los ciclistas en Bogotá, la métrica técnica más crítica de optimizar es el **Recall (Sensibilidad)**¹⁷. En este dominio de aplicación, un Falso Negativo (*FN*) representa un tramo de ciclorruta con una alta peligrosidad material activa que el algoritmo clasifica incorrectamente como seguro¹⁷. Esto induciría al biciusuario a transitar por una zona altamente vulnerable sin precauciones, elevando el riesgo de sufrir un atraco o lesiones personales¹³.

Por el contrario, un Falso Positivo (*FP*) representa clasificar como insegura una vía que en realidad no presenta amenazas inminentes, lo cual únicamente genera un costo marginal por desvío de ruta o una alerta preventiva no indispensable¹⁷. Por lo tanto, el umbral de decisión debe calibrarse para maximizar el Recall, manteniendo un equilibrio aceptable de Precision reflejado en el *F₁-Score* y el área bajo la curva ROC-AUC¹⁷.

Métricas de Eficiencia Criminológica

Dado que los recursos policiales y las capacidades de patrullaje de la Secretaría de Seguridad son intrínsecamente limitados, los modelos predictivos espaciales deben ser evaluados bajo métricas de eficiencia que consideren el área urbana intervenida frente a la densidad de delitos concentrados⁴⁴. Se establecen tres métricas clave validadas por el National Institute of Justice (NIJ):

El **Índice de Precisión Predictiva (PAI - Predictive Accuracy Index)** mide la capacidad del modelo para concentrar la mayor proporción de delitos reales dentro de la menor fracción de área urbana calificada como hotspot⁴⁴:

$$PAI(H) = \frac{\left(\frac{n(H)}{N(S)} \right)}{\left(\frac{|H|}{|S|} \right)}$$

Donde $n(H)$ representa la cantidad de hurtos registrados en el área predictiva hotspot H ,

$N(S)$ representa el consolidado total de hurtos en el conjunto de estudio S (en este caso, toda la extensión de ciclorrutas de Bogotá), $|H|$ es la longitud o área lineal delimitada como de alto riesgo y $|S|$ es la extensión completa del sistema vial de ciclorrutas⁴⁴. Un PAI alto indica una óptima focalización del riesgo⁴⁴.

El **Índice de Eficiencia Predictiva Modificado** (PEI^* - **Predictive Efficiency Index**) mide la eficiencia del algoritmo en comparación con el límite teórico de rendimiento máximo posible para una cantidad de área definida de hotspot⁵⁰:

$$PEI^*(H) = \frac{PAI(H)}{PAI_{max}(H)} = \frac{n(H)}{n^*(H)}$$

Donde $n^*(H)$ es la cantidad máxima teórica de hurtos de bicicletas que podrían capturarse en un área del mismo tamaño que $|H|$ si se seleccionaran de forma perfectamente descendente los puntos más densamente delictivos observados en los datos de validación⁵⁰. El PEI^* oscila entre 0 y 1, actuando como un estándar de optimización para la focalización de recursos de patrullaje preventivo del Plan Bogotá Camina Segura³⁹.

El **Índice de Tasa de Recaptura (RRI - Recapture Rate Index)** evalúa la estabilidad espacial y temporal de las predicciones, midiendo la proporción de delitos que ocurren en hotspots recién identificados frente a los hotspots históricos recurrentes, proporcionando un control contra la variabilidad aleatoria de los focos de criminalidad⁴⁶.

Estrategias de Validación Espacio-Temporal

La validación tradicional por partición aleatoria de datos (K-Fold tradicional) genera estimaciones sesgadas y excesivamente optimistas de las métricas debido a la autocorrelación espacial y temporal de las variables (la proximidad geográfica de la cicloinfraestructura y las lecturas climáticas tiende a asemejar los datos)⁴⁹. Para garantizar la generalización científica y la validez metodológica del modelo se ejecutan las siguientes estrategias de partición:

- **Validación Cruzada por Bloques Espaciales (Spatial Block K-Fold)**: En lugar de dividir las observaciones de las ciclorrutas de forma aleatoria, el mapa de Bogotá se segmenta en bloques geográficos continuos de escala predefinida (por ejemplo, cuadrículas hexagonales o límites administrativos de UPZ)⁴⁹. La asignación a los pliegues (folds) de entrenamiento y validación se realiza a nivel de bloque, garantizando que el modelo sea evaluado en zonas geográficamente independientes de los datos de entrenamiento, eliminando el sobreajuste espacial⁴⁹.
- **Validación de Omisión Simple con Búfer Espacial (Buffered Leave-One-Out CV - B-LOO CV)**: Al evaluar la predicción en un punto o tramo de ciclorruta específico, se omiten del conjunto de entrenamiento todas las observaciones que se encuentren dentro

de una distancia radial o de búfer geográfico determinado (p. ej., un radio de un kilómetro)⁴⁹. Esto reduce drásticamente el sesgo de proximidad y obliga al modelo a depender de las características físicas generales de la infraestructura y el entorno urbano, en lugar de memorizar la delincuencia histórica adyacente⁴⁹.

- **Partición por Horizonte Rodante Temporal (Rolling-Horizon Split):** Respeta la dirección lineal del tiempo mediante la partición estructurada en ventanas cronológicas deslizantes³. El modelo se entrena con los datos del período $[1, t]$ (por ejemplo, meses de enero a junio) y se valida evaluando su rendimiento estrictamente en el período posterior $[t + 1]$ (mes de julio), avanzando la ventana de forma secuencial sobre el histórico de denuncias del SIEDCO³.

Fuentes Científicas y Metodológicas de la Sección

La validación científica de los modelos de seguridad urbana se rige por estándares definidos en investigaciones metodológicas de alto impacto. La formulación matemática y el análisis

operativo del Índice de Eficiencia Predictiva Modificado (PEI^*) y el Índice de Precisión

Predictiva (PAI) provienen de los estudios y desafíos globales organizados por el National Institute of Justice (NIJ) de los Estados Unidos, con contribuciones analíticas clave de Veronica M. White, Joel Hunt y Brannon Green en el Security Journal⁴⁴. El análisis de los efectos de la autocorrelación espacial y el desarrollo de técnicas de validación cruzada espacial (como el Spatial K-Fold y el Buffered Leave-One-Out) se fundamenta en las guías metodológicas publicadas en revistas científicas de ecología y geografía del comportamiento como Nature y ResearchGate⁴⁹. Por último, el marco integrador de eficiencia espacial en la asignación de recursos públicos de seguridad urbana se sustenta en investigaciones recientes sobre el comportamiento de umbrales delictivos en ciudades inteligentes publicadas en Taylor & Francis Online⁴⁸.

Conclusiones Científicas e Implicaciones de Ingeniería de Software para la Transformación Territorial

El análisis de viabilidad técnica y metodológica demuestra que la construcción de un modelo predictivo basado en Machine Learning para la evaluación del riesgo de seguridad en las ciclorrutas de Bogotá en el año 2026 es plenamente viable y oportuno. La infraestructura de datos abiertos de Bogotá provee la granularidad geográfica y la consistencia histórica necesarias para alimentar algoritmos con un alto nivel de detalle espacial y temporal²¹. Para guiar la construcción del software orientado a la transformación del territorio, se consolidan las siguientes implicaciones y especificaciones de arquitectura del sistema de información:

1. Arquitectura de Integración de Datos (ETL) y Procesamiento

Dinámico

El sistema de información debe adoptar una arquitectura de integración híbrida de microservicios para interactuar de forma segura con los diferentes repositorios distritales. Se estructurará un flujo de extracción, transformación y carga (ETL) automatizado:

- Las variables espaciales estáticas de la cicloinfraestructura de la SDP²⁸ y el inventario de postes de iluminación de la UAESP³⁰ se capturarán mediante consultas periódicas semanales a los servicios de mapas tipo Web Feature Service (WFS) y REST expuestos por IDECA²³.
- La dimensión dinámica de riesgo temporal se actualizará a partir de los registros consolidados del SIEDCO de la Secretaría de Seguridad²⁴, procesando la tipificación del incidente bajo el código 905 de atracos en curso como indicio de alta vulnerabilidad en tiempo real³⁸.
- Las variables ambientales dinámicas del IDIGER se consumirán mediante llamadas de API REST cada hora al Sistema de Alerta de Bogotá, extrayendo las lecturas de los pluviómetros en las zonas de influencia de la red de ciclorrutas³⁵. Esto permitirá al modelo asimilar la relación causa-efecto de las lluvias torrenciales vespertinas con la deserción del flujo vial y la reducción de la vigilancia natural⁶.

2. Implementación de Diseño Físico Urbano CPTED como Predictor Crítico

Para romper con la dependencia exclusiva de datos históricos de delincuencia —que generan sesgos algorítmicos contra áreas vulnerables periféricas—, la arquitectura del software debe priorizar la inclusión de atributos CPTED como variables explicativas clave en el entrenamiento del modelo⁴. Se estructurará un índice dinámico de diseño físico urbano combinando la densidad de luminarias LED, el estado operativo del servicio público nocturno, la proximidad de infraestructuras de guardianes capaces (como los Centros de Atención Inmediata - CAI o el patrullaje de corredores de Rutas Seguras) y las características geométricas de la vía en el marco del Plan de Ordenamiento Territorial⁵. Al integrar estas variables físicas estables, se mitiga el sesgo de sobre-vigilancia y se desplaza el foco hacia variables de infraestructura accionables por las dependencias distritales¹⁵.

3. Pipeline de Entrenamiento y Optimización de Algoritmos

La viabilidad operativa del software para una plataforma ligera en dispositivos móviles o paneles de control de la Secretaría de Movilidad apunta al uso preferente de algoritmos de ensamble como **XGBoost o Random Forest**¹⁷. Estos modelos optimizan los costos de cómputo en servidores distritales y admiten una implementación fluida con frameworks en Python. Su entrenamiento incorporará un pipeline de optimización de hiperparámetros (como la optimización mediante la Colonia de Abejas Artificiales) para asegurar una estabilidad frente a datos faltantes o ruido en las denuncias históricas¹⁴. La opacidad algorítmica se resolverá mediante la integración nativa de librerías SHAP en la API del backend, permitiendo

documentar con explicabilidad científica las causas de la elevación del índice de riesgo para cada segmento vial¹⁷.

4. Configuración de Alertas y Sistema de Validación Científica

El backend del software incorporará un módulo de validación cruzada espacial (Spatial Block K-Fold) y temporal en su fase de desarrollo fuera de línea (offline), garantizando que las métricas de rendimiento estimadas no sufran de sobreajuste geográfico y sean estables en el tiempo⁴⁹. Para la visualización e interacción con el usuario (biciusuarios y operadores distritales):

- Se priorizará un ajuste del umbral de decisión para alcanzar niveles de **Recall** superiores al ochenta y cinco por ciento, minimizando la omisión de zonas de alto riesgo para proteger la integridad física de los ciclistas¹⁷.
- La eficiencia en el direccionamiento de recursos estatales de prevención o envío de patrullajes se evaluará y optimizará bajo los indicadores estandarizados de **PAI y PEI***, garantizando que los corredores de vigilancia priorizados capturen de forma real la mayor proporción de delitos potenciales bajo las restricciones de recursos policiales de la ciudad⁴⁴.
- Para garantizar la protección de la información ciudadana, el sistema aplicará directrices estrictas de anonimización y privacidad diferencial sobre los datos personales de las víctimas extraídos del SIEDCO antes de iniciar el procesamiento del modelo¹⁶.

Obras citadas

1. Key Elements of Predictive Policing Include Crime Analysis, Crime Mapping and Geographies - ResearchGate, https://www.researchgate.net/publication/371695297_Key_Elements_of_Predictiv_e_Policing_Include_Crime_Analysis_Crime_Mapping_and_Geographies
2. Riding the Risk: A Spatiotemporal Analysis of Bicycle Theft on College Campuses, <https://www.crimrxiv.com/pub/bipedal>
3. A systematic review on spatial crime forecasting - PMC - NIH, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7319308/>
4. Crime Spatiotemporal Prediction Through Urban Region Representation by Using Building Footprints - MDPI, <https://www.mdpi.com/2504-2289/9/12/301>
5. New Bern Corridor Study Crime Prevention Through Environmental Design, https://cityofraleigh0drupal.blob.core.usgovcloudapi.net/drupal-prod/COR28/NBCS_CPTED.pdf
6. Ideas for Action Health & Public Safety - Institute for Local Government, <https://www.ca-ilg.org/post/ideas-action-health-public-safety>
7. Predicting Bicycle Theft in Milan (IT) An Aoristic Analysis | Journal of Science and Cycling, <https://www.jsc-journal.com/index.php/JSC/article/view/522>
8. (PDF) Ride Shield: Bike Theft Analysis - ResearchGate, https://www.researchgate.net/publication/403593618_Ride_Shield_Bike_Theft_An_alysis
9. Bicycle Theft Detection by using YOLOv5s and DeepSORT algorithm - IEEE

- Xplore, <https://ieeexplore.ieee.org/document/10955901/>
10. La criminología predictiva: ¿un futuro próximo o una ficción en lontananza? | Novum Jus, <https://novumjus.ucatolica.edu.co/article/view/5982/6031>
 11. Pronóstico del Hurto de Bicicletas en Bogotá durante la Ciclovía - Fundación Universitaria Los Libertadores,
<https://revistas.libertadores.edu.co/index.php/ACI/article/download/1298/1215/3467>
 12. A temporal approach to urban crime forecasting using recurrent neural networks - Redalyc, <https://www.redalyc.org/journal/7261/726182578011/html/>
 13. Sistema de seguridad para bicicletas Jorge Edison Jiménez Leguizamón
Universitaria Agustiniiana Facultad de Ingeniería Progra - Repositorio Institucional UniAgustiniana,
<https://repositorio.uniagustiniana.edu.co/bitstreams/7f7238f8-0335-44b3-8b2e-a8f2062407ac/download>
 14. Pedaling Against Theft: An Analysis of Bicycle Theft in Toronto | by Liam Ma | Medium,
<https://medium.com/@flexpoly321/pedaling-against-theft-an-analysis-of-bicycle-theft-in-toronto-73f45390b352>
 15. Big Data Surveillance: The Case of Policing - PMC,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC10846878/>
 16. Inteligencia artificial en la seguridad pública y en el sistema penal en América Latina | Fair Trials,
<https://www.fairtrials.org/app/uploads/2024/08/Inteligencia-artificial-en-la-seguridad-publica-y-en-el-sistema-penal-en-America-Latina.pdf>
 17. Spatiotemporal Crime Prediction and Forecasting Using Machine Learning and Deep Learning Models - ResearchGate,
https://www.researchgate.net/publication/400845671_Spatiotemporal_Crime_Prediction_and_Forecasting_Using_Machine_Learning_and_Deep_Learning_Models
 18. Modelo de redes neuronales para predecir la tendencia de víctimas de secuestro en Colombia,
<https://revistas.unisimon.edu.co/index.php/innovacioning/article/download/4702/4939/38023>
 19. Community-engaged crime prevention through environmental design and reductions in violent and firearm crime - PMC,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12404146/>
 20. La inteligencia artificial y la video-vigilancia en la predicción y detección de delitos en espacio-tiempo: una revisión sistemática,
http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S1794-31082023000100011
 21. Índice de condiciones de seguridad nocturna por localidad. Bogotá D.C. Año 2019 | Ideca,
<https://www.ideca.gov.co/recursos/mapas/indice-de-condiciones-de-seguridad-nocturna-por-localidad-bogota-dc-ano-2019>
 22. Corredor Verde. POT Bogotá D.C. - Dataset,
<https://datosabiertos.bogota.gov.co/en/dataset/corredor-verde-pot-bogota-d-c>

23. Comisión IDECA,
[https://www.ideca.gov.co/sites/default/files/20190621PresentacionSegundaSesi%C3%B3nComisionIDECA%20\(0\)_compressed.pdf](https://www.ideca.gov.co/sites/default/files/20190621PresentacionSegundaSesi%C3%B3nComisionIDECA%20(0)_compressed.pdf)
24. Metadata SIEDCO, https://oaiee.scj.gov.co/Documentos/Metadata_Siedco.pdf
25. Layer: Hurto de bicicletas por Oportunidad (ID: 15),
https://oaiee.scj.gov.co/agc/rest/services/Tematicos_Pub/SIEDCO_Delitos_Pub/FeatureServer/15
26. Anexo 1 - Secretaria Distrital de Seguridad, Convivencia y Justicia,
https://scj.gov.co/sites/default/files/2025-08/Anexo%201%20-%20%20Diagn%C3%B3stico%20detallado_0.pdf
27. Informe Anual de Seguridad 2022 | ProBogotá,
<https://www.probogota.org/wp-content/uploads/2023/10/Informe-Anual-de-Seguridad-2022.pdf>
28. Red Cicloinfraestructura. POT Bogotá D.C. - Conjunto de datos,
<https://datosabiertos.bogota.gov.co/dataset/red-cicloinfraestructura-bogota-d-c>
29. Dataset - Datos Abiertos Bogotá,
https://datosabiertos.bogota.gov.co/en/dataset?tags=Movilidad&res_format=KMZ
30. Alumbrado Público, Bogotá D.C. - Conjunto de datos,
https://datosabiertos.bogota.gov.co/dataset/luminarias_upz-bogota-d-c
31. 101 conjuntos de datos encontrados para "PRESTACIÓN DE SERVICIOS ALUMBRADO PÚBLICO" - Datos Abiertos Bogotá,
https://datosabiertos.bogota.gov.co/dataset?q=PRESTACI%C3%93N+DE+SERVICIOS+ALUMBRADO+P%C3%9ABLICO&ext_bbox=&ext_prev_extent=
32. BASE DE DATOS MODERNIZACIÓN ALUMBRADO PÚBLICO JUNIO 2020-MAYO 2021 - Datos Abiertos Bogotá,
<https://datosabiertos.bogota.gov.co/dataset/base-de-datos-modernizacion-alumbrado-publico-junio-2020-mayo-2021>
33. 74 conjuntos de datos encontrados para "INFRAESTRUCTURA DE ALUMBRADO PÚBLICO " - Datos Abiertos Bogotá,
https://datosabiertos.bogota.gov.co/dataset/?q=INFRAESTRUCTURA+DE+ALUMBRADO+P%C3%9ABLICO+&ext_bbox=&ext_prev_extent=&organization_limit=0&organization=uaesp
34. 3. Estaciones IDIGER de precipitación y temperatura en Bogotá 2017 – 2021,
<https://www.idiger.gov.co/cambio-climatico/lluvias-y-temperatura-en-bogota/estaciones-idiger-precipitacion-y-temperatura-bogota-2017-2021>
35. Dataset - Datos Abiertos Bogotá,
https://datosabiertos.bogota.gov.co/en/dataset/?organization=idiger&tags_limit=0
36. Incremento de lluvias en un 160% por encima del promedio histórico - IDIGER,
<https://www.idiger.gov.co/w/incremento-de-lluvias-en-un-160-por-encima-del-promedio-historico>
37. Proyecto de Acuerdo 338 de 2020 Concejo de Bogotá, D.C.,
<https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=142299>
38. Download - Datos Abiertos Bogotá,
<https://datosabiertos.bogota.gov.co/dataset/9bdf518e-b756-4865-983f-0521111fbc41/resource/fa426f3f-b2b0-491b-8287-dfeca438f558/download/guiatipificacioninci>

[dentes.csv](#)

39. Disminuye hurto a personas y a celulares con avances de Bogotá Camina Segura,
<https://bogota.gov.co/mi-ciudad/seguridad/estos-son-los-resultados-de-la-estrategia-bogota-camina-segura>
40. Bogotá firma pacto de corresponsabilidad con ciclistas para fortalecer la seguridad y la convivencia en las ciclorrutas,
<https://scj.gov.co/prensa/noticias/bogota-firma-pacto-de-corresponsabilidad-con-ciclistas-para-fortalecer-la-seguridad>
41. Registro bici: la herramienta que permitió que Lida recuperara su bicicleta - Alcaldía de Bogotá,
<https://bogota.gov.co/mi-ciudad/seguridad/registro-bici-la-herramienta-que-permitio-que-lida-recuperara-su-bici>
42. ¿Por qué en Bogotá llueve más en las tardes? - IDIGER,
<https://www.idiger.gov.co/w/%C2%BFpor-que-en-bogota-llueve-mas-en-las-tardes->
43. The Role of AI in Predictive Modelling for Sustainable Urban Development: Challenges and Opportunities - MDPI,
<https://www.mdpi.com/2071-1050/17/11/5148>
44. Rotational grid, PAI-maximizing crime forecasts - Office of Justice Programs,
<https://www.ojp.gov/pdffiles1/nij/grants/251203.pdf>
45. Predicting Spatiotemporal Crimes: A Framework Leveraging Ensemble Learning - Suresh Gyan Vihar University,
https://www.gyanvihar.org/journals/wp-content/uploads/2024/Page_30_to_36.pdf
46. Evaluation of a Hyperparameter Tuned Random Forest Algorithm Based on Artificial Bee Colony for Improving Accuracy and Precision of Crime Prediction Model - Science Publishing Group,
<https://sciencepublishinggroup.com/article/10.11648/j.ajbes.20251103.16>
47. Innovative LSGTime Model for Crime Spatiotemporal Prediction Based on MindSpore Framework - arXiv, <https://arxiv.org/html/2503.20136v1>
48. Full article: Optimal prediction threshold and spatial characteristics of burglary crime across cities - Taylor & Francis,
<https://www.tandfonline.com/doi/full/10.1080/24754269.2026.2665854>
49. (PDF) Spatial validation reveals poor predictive performance of large-scale ecological mapping models - ResearchGate,
https://www.researchgate.net/publication/344241901_Spatial_validation_reveals_poor_predictive_performance_of_large-scale_ecological_mapping_models
50. Real-Time Crime Forecasting Challenge Posting - National Institute of Justice,
<https://nij.ojp.gov/funding/real-time-crime-forecasting-challenge-posting>
51. A Discussion of Current Crime Forecasting Indices and An Improvement to the Prediction Efficiency Index for Applications | National Institute of Justice,
<https://nij.ojp.gov/library/publications/discussion-current-crime-forecasting-indices-and-improvement-prediction>
52. A review of machine learning for modeling air quality: Overlooked but important issues,
https://www.researchgate.net/publication/377578861_A_review_of_machine_learn

[ing_for_modeling_air_quality_Overlooked_but_important_issues](#)